

دانشگاه صنعتی امیرکبیر (پلیتکنیک تهران) دانشکده مهندسی کامپیوتر



درس رایانش ابری

تمرین سوم آشنایی با map reduce و اسپارک

طراحی تمرین خانم هاشمیپور و آقای اسد

> استاد درس آقای دکتر جوادی

نكات تمرين

- سوالات خود را میتوانید در گروه مشترک با تدریسیاران مطرح کنید.
- پاسخ تمرین را در قالب یک فایل زیپ با فرمت zip.3SID_HW ارسال بفرمایید.
 - لطفا پاسخ خود را تا تاریخ ۸/ دی/ ۱۴۰۲ در سامانه بارگذاری فرمایید.
- پاسخ به تمرینها انفرادی است. از استفاده از کدهایی که بر آنها مسلط نیستید بپرهیزید.
 - تمرین تحویل آنلاین خواهد داشت.

بخش اول، آشنایی با MapReduce

در این بخش به پیادهسازی دو الگوریتم گرافی با استفاده از MapReduce می پردازید.

مسئله كوتاه ترين مسير

حتما با مسئله کلاسیک کوتاهترین مسیر آشنایی کامل دارید. در این مسئله بین راسهای گراف با طی یالهای مختلف میتوان جابجا شد و از مبدا به مقصد رسید. الگوریتم Dijkstra نمونهای برای حل این مورد است.

در این بخش، با استفاده از این الگوریتم در دو فاز مجزا map و reduce بر روی مجموعه دادهای از نقاط مختلف یک کشور، مسیریابی کرده و بهترین آنها را انتخاب می کنیم. تفاوتی که پیاده سازی این الگوریتم با آنچه در درس ساختمان داده و الگوریتم فرا گرفته اید، اجرای آن به صورت جابهای موازی MapReduce است.

خوب است در ابتدا مروری بر پیادهسازی الگوریتم کلاسیک Dijkstra داشته باشید. در ادامه سودوکد این الگوریتم آورده شده است.

```
1: DIJKSTRA(G, w, s)
        d[s] \leftarrow 0
 2:
        for all vertex v \in V do
 3:
             d[v] \leftarrow \infty
        Q \leftarrow \{V\}
 5:
        while Q \neq \emptyset do
 6:
             u \leftarrow \text{ExtractMin}(Q)
 7:
             for all vertex v \in u. AdjacencyList do
 8:
                 if d[v] > d[u] + w(u, v) then
 9:
                     d[v] \leftarrow d[u] + w(u,v)
10:
```

همانطور که در بالا مشاهده می شود، با استفاده از از یک صف دارای اولویت که در هر لحظه یک لیست مرتب شده از فاصله راسها نگه می دارد، کوتاه ترین مسیر از نقطه شروع تا پایان انتخاب می شود. این عملکرد در MapReduce قابل پیاده سازی نیست چون نیازمند دانش کلی از همه نودها است. چیزی که مانع پیاده سازی و اجرا به صورت موازی می شود.

کدی برای الگوریتم Dijkstra به صورت موازی و در قالب دو فاز map و reduce بر روی گراف جهتدار ارائه دهید و آن را شرح دهید.

راهنمایی: شما می توانید از روشهای مختلفی به این مسئله نگاه کنید. یک راه حل ساده این است که در ابتدا فرض کنید تمامی یالها وزن برابر یک دارند. در این حالت راسهای متصل به راس ابتدایی فاصله یک دارند. راسهای متصل به این راسها نیز فاصله ۱ + ۱ دارند و به همین صورت تا راس مقصد. اما چیزی که باید توجه داشته باشید آن است که در این حالت هم ممکن است بین دو راس، چندین مسیر با تعداد راس میانی مختلف قرار بگیرند که موثر در طول مسیر پیشنهادی است. پس باید از میان آنها، کوتاه ترین انتخاب شود. بدین صورت فازهای ها و برای حالت کلی با و زنهای مختلف مورت فازهای کنید.

مسئله رتبه صفحه(PageRank)

احتمالا نام این الگوریتم نیز به گوشتان خورده است. الگوریتمی پیشنهادی توسط گوگل که به وسیله ارجاعهایی که در هر صفحه وبسایت قرار دارد، صفحات وب را مرتب می کند. فرض کنید یک کاوشگر وب یک صفحه را می بیند و به صورت تصادفی بر روی یک لینک از آن صفحه کلیک می کند و این کار را بینهایت بار تکرار می کند. این الگوریتم با یک توزیع احتمالاتی روی مجموعه رئوس(در اینجا صفحه وب) بیان می کند که یک صفحه به چه احتمالی توسط کاوشگران بازدید خواهد شد. ایده اصلی این الگوریتم این است که اگر صفحهای کیفیت خوبی داشته باشد، احتمالا صفحات دیگری با رتبه بالا این صفحه را تایید کرده اند. به همین صورت و طی یک الگوریتم پیایی، امتیاز هر راس براساس امتیاز رئوس متصل بدست می آید.

امتیاز هر راس به صورت زیر محاسبه میشود.

$$P(n) = \alpha \left(\frac{1}{|G|}\right) + (1 - \alpha) \sum_{m \in L(n)} \frac{P(m)}{C(m)}$$

که در آن [G] تعداد کل گره ها (صفحات) در گراف، α ضریب پرش تصادفی، L(n) مجموعه صفحاتی است که به n لینک دارند، و (C(m) تعداد لینکهای صفحه m است.

در ابتدای هر iteration؛ یک راس مقدار امتیاز PageRank خود به سایر همسایههای متصل خواهد داد و در انتهای iteration، مقدار تمامی این امتیازهای دریافت شده هر راس، امتیاز جدید آن را تعیین می کنند. این الگوریتم تا جایی ادامه پیدا می کند که تغییر چندانی در امتیاز هر یک دیده نشود.

با استفاده از توضیحات بالا، در این بخش این الگوریتم را برای اجرا به صورت موازی و در قالب MapReduce بر روی یک گراف جهتدار پیادهسازی کنید.

نكا<u>ت</u>

- کد شما به صورت زیر ورودی بگیرد. به ازای هر ورودی، خروجی هر مرحله map و reduce باید قابل مشاهده باشد. مثالهای زبر بدون هیچ مشکلی باید در ورودی قرار گرفته و اجرا شوند.
 - مسئله کوتاهترین مسیر

```
# Example graph
graph = {
    "A": {"Distance": 0, "AdjacencyList": {"B":10,"C":5}},
    "B": {"Distance": float('inf'), "AdjacencyList": {"C":2,"D":1}},
    "C": {"Distance": float('inf'), "AdjacencyList": {"E":2,"B":3,"D":9}},
    "D": {"Distance": float('inf'), "AdjacencyList": {"E":4}},
    "E": {"Distance": float('inf'), "AdjacencyList": {"A":7,"D":6}}
}
```

• مسئله رتبه صفحه

```
# Example graph
graph = {
    "A": {"PageRank": 1.0, "AdjacencyList": ["B", "C"]},
    "B": {"PageRank": 0.5, "AdjacencyList": ["A"]},
    "C": {"PageRank": 0.5, "AdjacencyList": []}
}
```

- اجرای الگوریتم بر روی کلاستر هدوپ نمره امتیازی دارد. بدین منظور docker compose قرار داده شده تمامی منابعی که نیاز دارید را بالا خواهد آورد. دیتاستهای مجزایی نیز قرار در پوشه hadoop/data قرار گرفتهاند که جابهای MapReduce بر روی آنها اجرا خواهند شد.
 - میتوانید از یکی از زبانهای جاوا و یا پایتون برای پیادهسازی استفاده کنید.
 - در گزارشی که تهیه می کنید باید به توضیح الگوریتم پیشنهادی بپردازید.
 - کد map reduce را حتما آپلود کنید.

بخش دوم، آشنایی با اسپارک

آپاچی اسپارك یک فریمورك متن باز است که در سال 2009 توانست با بهینهسازی 100 برابر نسبت به پلتفرم روز آن زمان یعنی Hadoop جایگاه بالایی در میان علاقهمندان به مباحث BigData باز کند. دلیل قدرت این فریمورك وجود هسته مرکزی با یک موتور پردازش توزیع یافته کلان داده است که میتواند به خوبی مقیاس بندی شود. همچنین یکی دیگر از مواردی که باعث افزایش کارابی اسپارك شده استفاده از مکانیسم حافظه نهان هنگام استفاده از دادههایی است که قرار است دوباره در برنامه استفاده شود. این کار باعث کاهش سریار ناشی از خواندن و نوشتن از دیسک می شود. با استفاده از مکانیسم حافظه نهان در اسپارك داده ها یک بار از دیسک خوانده می شوند و در حافظه اصلی کش می شوند و عملیاتهای متفاوت بر بروی آن اجرا می شود. در نتیجه استفاده از این روش نیز باعث کاهش چشمگیر سریار ناشی از ارتباط با دیسک در برنامه ها و بهبود کارایی می شود. با توجه به قدرت این پلتفرم یکی از پتانسیل های استفاده از آن مبحث استریم دیتا می باشد. امروزه شرکتهای تکنولوژی زیادی از آن با مقاصد تجاری استفاده می کنند. از طرف دیگر ویژگی ساده بودن یادگیری آن موجب شده تا این فریمورك به عنوان یک مهارت میبایست در رزومه توسعه دهندگان قرار داشته باشد. در این تمرین تلاش شده تا از توانایی های ابتدایی این پلتفرم استفاده شود.

براي اين تمرين يک فايل داکر کامپوز آماده شده است که برای شما پيشنيازهای زيرساختی تمرين را فراهم ميکند. از جمله 1 کلاستر hdfs براي ذخيرهسازي فايل در فضاي ابری به صورت توزيع شده که از يک کانتينر namenode و دو کانتينر datanode تشکيل شده است. 2 کلاستر اسپارك که از يک مستر و دو ورکر تشکيل شده است که برای پردازش فايلها به صورت موازی و توزيع شده از آن استفاده می شود. يک فايل جوپيتر نوتبوك که در نتورك داکري همه اينها قرار گرفته تا به راحتی متصل باشد و اين فايل بايد توسط شما به زبان پايتون کامل گردد.

- Spark Master: http://localhost:9090
- Namenode: http://localhost:9870
- Jupyter Notebook: http://localhost:8888

برای راه اندازی Hadoop بالا آوردن کانتینرهای ذکر شده، کافی است دستور زبر را اجرا کنید:

hw3 — -zsh — 191×53

Last login: Thu Dec 7 12:10:15 on ttys000

[helia@HeliaHashemipour hw3 % sudo ./run-cluster.sh

در صورتی که سیستم شما اینتل نبود این خط از داکرفایل را به این شکل عوض کنید.

/ENV JAVA_HOME=/usr/lib/jvm/java-8-openjdk-arm64

توضيحات ديتاستها

برای این تمرین دو دیتاست در نظر گرفته شده است.

دیتاست اول مرگ و میر ویروس کرونا)

- این دیتاست شامل رکوردهایی با مضمون تعداد مرگ و میر ویروس کرونا میباشد.
 - رکوردهای این دیتاست شامل ۱۲ ستون است.
- در برخی از رکوردهای دیتاست، ممکن است اطلاعات یک ستون وجود نداشته باشد.

دیتاست دوم(بترنهای باکتری Ecoli)

برای آشنایی بهتر با قابلیتهای PySpark این دیتاست به صورت فایل .txt درنظر گرفته شده است. فایل Ecoli.txt به بطور معمول دادههای دنباله ژنومی باکتری اشریشیاکلی از الله (E. coli) را شامل می شود. اشریشیاکلی یک باکتری است که به طور متداول در تحقیقات بیولوژیکی مورد مطالعه قرار می گیرد و دنباله ژنومی آن به صورت فایلهای متنی مانند Ecoli.txt در دسترس است. فایلهای دادههای دنباله ژنومی مانند Ecoli.txt سازنده این ارگانیسم دنباله ژنومی مانند DNA سازنده این ارگانیسم است که کد ژنتیکی است که کد ژنتیکی است که کد ژنتیکی است. در مورد اشریشیاکلی، این فایل هامل یک دنباله ژنومی برای اهداف مختلفی استفاده می کنند، از جمله تحلیل ژنتیکی، شناسایی ژنها، مطالعه روابط تکاملی و درک ترکیب ژنتیکی و عملکرد ارگانیسمها مانند اشریشیاکلی.

موارد زیر را در فایل گزارش نمایش دهید:

- نمایش کانتینرهای ایجاد شده
- توضيح وظيفه هركدام از كانتينرها در Hadoop
- نمایش WebUI برای NameNode و فایل سیستم آن

<u>نكات</u>

دیتای اولیه در دو فایل فشرده شده به صورت csv و txt در اختیار شما قرارداده شده است که دیتاست اول شامل اطلاعات مربوط به مرگ و میر ویروس کرونا و دیتاست دوم شامل پترنهای باکتری Ecoli میباشد. در این تمرین از شما خواسته شده است، ابتدا کانتینرهای مورد نیاز را بالا آورده سپس در آدرس http://localhost:8888 به سوالاتی که در فایل jupyter notebook مربوط به هر دو دیتاست میباشد، پاسخ دهید.

• انتظار میرود گزارش مربوطه برای این بخش، شامل سوالات داخل دستورکار و نوتبوک باشد.

پیروز باشید. تیم تدریسیاری درس رایانش ابری